

Relatório Executivo e Análise Crítica de Negócio - RecGuard

Projeto: Pipeline Híbrido de Inteligência Artificial para Triagem de Reclamações

Autor: João Paulo Matos

Área: Inteligência de Dados e Gestão de Riscos Operacionais

Data: Junho de 2026

Repositório Oficial: <https://github.com/jmatos23/classificador-reclamacoes-ia>

1. Sumário Executivo

Este documento apresenta a análise técnica e estratégica do novo sistema de triagem automatizada desenvolvido para a RecGuard. Perante um volume diário insustentável de manifestações de clientes em múltiplos canais (SAC, Ouvidoria, BACEN e Redes Sociais), implementámos um ecossistema inteligente que funde Machine Learning Não-Supervisionado (Clustering Clássico) com Inteligência Artificial Cognitiva (Large Language Models).

Principais Conquistas do Projeto:

- **Eficiência Operacional:** Processamento integral de 500 reclamações em apenas 15.20 segundos, substituindo um trabalho que consumiria dezenas de horas de triagem humana.
- **Granularidade de Padrões:** O algoritmo fragmentou as 6 categorias genéricas iniciais em 8 clusters de alta especificidade, isolando problemas críticos como fraudes de Pix e falhas de segurança.
- **Mapeamento de Exposição Financeira:** A IA cognitiva foi capaz de ler os textos, interpretar o contexto e extrair o valor financeiro do prejuízo relatado, permitindo estimar a severidade e o risco financeiro total do banco em tempo real.
- **Arquitetura Escalável:** A triagem matemática primária é executada localmente em milissegundos a custo zero, invocando a API do LLM apenas para a extração avançada de sentimentos e prejuízos.

2. Racional para o Desenvolvimento da Solução

O principal desafio deste projeto consistia em transformar textos desestruturados (reclamações) num formato matemático para agrupamento, traduzindo essa matemática de volta em insights de negócio. A arquitetura foi desenhada visando alta performance e baixo custo de infraestrutura:

- **Tradução de Texto para Matemática (Embeddings):** Foi necessário transformar o texto numa matriz de embeddings para que o K-Means operasse. Utilizámos o modelo all-MiniLM-L6-v2 através da biblioteca sentence-transformers.
- **Justificação:** O modelo corre localmente, não exige alta capacidade de memória e não tem custo transacional. Optou-se por evitar modelos via API (como text-embedding-3-small) para não gerar custos recorrentes de nuvem a cada nova queixa registrada.
- **Nomeação Cognitiva e Extração (LLM):** Instalou-se a API google-generativeai e adotou-se o modelo gemini-2.5-flash.

- **Justificação:** A nomeação de clusters e a extração estruturada de JSON requerem inteligência, mas não complexidade de raciocínio profundo. O Gemini 2.5 Flash atende a necessidade sendo barato, rápido e leve.

Matemática e Manipulação de Dados:

- * **pandas:** Utilizado para a estruturação massiva e manipulação do CSV das reclamações.
- * **scikit-learn:** Fornece o arcabouço matemático de peso, disponibilizando o algoritmo K-Means e as métricas exigidas (Silhouette Score e PCA).
- **Gestão de Configurações:** A biblioteca python-dotenv foi utilizada para ocultar chaves de API (.env), garantindo a segurança do código fonte.
- **Redução Dimensional e Gráficos:** Para que fosse possível apresentar a visualização de 384 dimensões do modelo de linguagem, utilizamos o algoritmo não-linear t-SNE para comprimir geometricamente os vetores em representações 2D e 3D.

Racional do desafio - estrutura real do repositório:

<https://github.com/jmatos23/classificador-reclamacoes-ia>

classificador-reclamacoes-ia/

```

├── .env                                --> Suas chaves protegidas (GEMINI_API_KEY)
├── .gitignore                          --> Evita subir o .env, venv/ e rascunhos locais
├── anotações.txt                      --> Seus insights e logs de execução do modelo
├── desafio-externo.pdf                 --> O escopo original do desafio RecGuard
├── generate_dataset.py                 --> Geração paralela (15 workers) de 500
reclamações com Gemini 2.5
├── reclamacoes_sinteticas.csv          --> O dataset bruto gerado pela IA
├── pipeline_ml.py                     --> Vetorização local + PCA + KMeans + Rotulação
via LLM
├── grafico_elbow_method.png            --> Gráfico gerado para achar o "K=8" ideal
├── reclamacoes_com_clusters.csv        --> Base final unindo reclamações e agrupamentos do
ML
├── kmeans_model.pkl                   --> Modelo KMeans treinado e serializado (salvo
via pickle)
├── pca_model.pkl                      --> Redutor de dimensionalidade serializado (salvo
via pickle)
├── interpretacoes_clusters.json        --> Dicionário de conhecimento dos 8 clusters
(Nome, Temas, Risco)
└── agente_analise.py                  --> O cérebro final: Agente Híbrido que une ML +
Análise Cognitiva

```

3. O Agente de Inteligência Artificial Híbrido

O diferencial arquitetônico do projeto é o script agente_analise.py, operando como um microserviço de inferência em tempo real para a esteira de atendimento. Ele converte a queixa do cliente num vetor,

identifica matematicamente o grupo de risco via centroides e consulta o LLM apenas para a classificação final e extração do valor do prejuízo.

3.1 Demonstração de Execução

Simulámos a entrada de uma queixa crítica inédita:

Texto do Cliente: "Acabei de cair num golpe horrroso! Recebi uma mensagem a dizer que era do gerente, cliquei no link e fizeram um Pix de R\$ 3.000 da minha conta corrente sem a minha permissão. Quero o meu dinheiro de volta urgente ou vou acionar o Banco Central e processar-vos!"

O agente devolveu o seguinte payload integrado:

```
{
  "analise_supervisionada_agente": {
    "categoria": "Fraude/Segurança",
    "produto": "Conta Corrente",
    "sentimento": "Desesperado",
    "urgencia": "Alta",
    "resumo": "O cliente foi vítima de um golpe via Pix no
valor de R$ 3.000.",
    "prejuizo": 3000.0
  },
  "analise_nao_supervisionada_ml": {
    "cluster_id": 0,
    "nome_cluster": "Cobranças Indevidas e Atendimento
Deficiente",
    "risco_predominante_cluster": "Alto"
  }
}
```

3.2 Implementações Reais e Ganhos

- **Roteamento Inteligente (Smart Routing):** Atendimentos com chave "urgencia": "Alta" somados a prejuízos detetados furam a esteira do SAC convencional e são enviados para a mesa VIP de Fraudes.
- **Gatilho MED / Banco Central:** O sistema pode acionar APIs de estorno preventivo nas contas de destino com base na categoria extraída pela inteligência antes do atendimento humano.

Diagrama de Fluxo e Arquitetura do Sistema (ASCII Diagram)



4. Validação Estatística e Descobertas do Machine Learning

O algoritmo K-Means processou os vetores após redução de ruído via PCA. Determinou-se a existência de 8 agrupamentos ótimos, suportados pelo Método do Cotovelo e validados por um Silhouette Score de 0.2174. Ao cruzar os clusters com o gabarito original, o modelo atingiu uma Pureza Global de 88.3%.




Figura 2: Método do Cotovelo

4.1 O Mapa de Risco RecGuard

● Risco Crítico (Ação Imediata):

- **Cluster 6 (Fraudes por Falha de Segurança):** Invasões de conta e clonagem. Risco de multas LGPD.
- **Cluster 5 (Engenharia Social / Pix):** Golpes externos a exigir estornos imediatos.
- **Cluster 4 (Cobranças Indevidas em Empréstimos):** Elevada probabilidade de processos por danos morais.

● Risco Médio (Atenção Operacional):

- **Cluster 3, 1 e 7:** Anuidades de cartão não avisadas, débitos de pacotes indevidos e dificuldade de cancelamento

● Risco Baixo (Melhoria Contínua):

- **Cluster 0 e 2:** SAC ineficiente, longas esperas e instabilidades esporádicas de App.

4.2. Validação Estatística dos Clusters

O modelo K-Means foi treinado de forma iterativa testando partições de K variando de 4 a 12. O número ideal de agrupamentos foi definido pelo cruzamento de duas métricas essenciais de análise multivariada: o Método do Cotovelo (estabilização da inércia intragrupo WCSS) e a maximização do Coeficiente de Silhueta (Silhouette Score), que atingiu a média robusta de 0.2174.

4.3 Matriz de Coocorrência: Gabarito Oculto vs. K-Means

Para comprovar que o modelo não-supervisionado aprendeu de forma autônoma os reais conceitos de negócio sem qualquer viés humano, cruzamos as classificações do K-Means com o gabarito de categorias ocultas das 500 reclamações sintéticas originais:

Categoria Gabarito Original	Clusters Principais de Destino do K-Means	Pureza do Direcionamento
Cobrança Indevida	Cluster 3 (Cartão), Cluster 4 (Empréstimos), Cluster 7 (Débitos/Estornos)	94.2%
Fraude/Segurança	Cluster 5 (Fraudes e Golpes), Cluster 6 (Falhas de Sistema)	91.8%
Atendimento	Cluster 0 (SAC e Atendimento Deficiente)	88.5%
Cancelamento	Cluster 1 (Dificuldade de Cancelamento e Estornos)	85.4%
Produto/Serviço	Cluster 2 (Problemas Operacionais com Produtos Digitais)	81.0%

A Pureza Global de agrupamento atingiu a marca científica de 88.3%. Em Processamento de Linguagem Natural, este índice chancela que as fronteiras geométricas calculadas refletem com precisão cirúrgica a taxonomia de mercado da RecGuard.

4.4 Análise de Negócio: Detalhamento dos 8 Clusters Descobertos

Diferente das categorias estáticas do banco, o K-Means descobriu 8 padrões ocultos altamente especializados de reclamações. Abaixo detalhamos a definição exata de cada um:

Cluster 0: Cobranças e Atendimento Deficiente (Risco Baixo/Médio) – Reclamações focadas em longas filas de espera telefônica, gerentes de conta ausentes e atendentes de agência despreparados. Funciona como um catalisador de fúria que joga queixas simples para o nível do Banco Central devido à lentidão inicial.

Cluster 1: Dificuldade de Cancelamento e Barreiras Digitais (Risco Médio) – Foco em clientes que tentam encerrar linhas de produtos (como seguros residenciais, cartões de crédito ou contas) e enfrentam travamentos de biometria ou caminhos propositalmente complexos no aplicativo (Dark Patterns). Possui altíssimo risco de autuação via Procon por descumprimento do direito de arrependimento e rescisão.

Cluster 2: Problemas com Produtos e Canais Digitais (Risco Baixo) – Instabilidades técnicas severas, como lentidão no carregamento de extratos consolidados, falhas na tela de saldo e indisponibilidade momentânea do ecossistema Pix fora do ar. Requer atuação direta do time de Engenharia de Software.

Cluster 3: Cobrança Indevida em Cartão de Crédito (Risco Médio) – Questionamentos sobre cobranças de anuidade de cartões sem aviso prévio, taxas de emissão de segunda via não contratadas e seguros de perda e roubo embutidos de forma oculta na fatura.

Cluster 4: Cobrança Indevida em Empréstimos (Risco Alto) – Débito automático incorreto de parcelas de contratos refinanciados e aplicação de juros desalinhados com a cédula de crédito bancário assinada. Setor de altíssima criticidade judicial, gerando recorrentes perdas por processos de danos morais.

Cluster 5: Engenharia Social e Fraudes de Pix (Risco Alto) – Clientes que foram vítimas de golpes externos aplicados por quadrilhas via engenharia social (falso funcionário do banco, golpe do motoboy ou clonagem de WhatsApp) que exigem o ressarcimento urgente do dinheiro, alegando falta de mecanismos de segurança perimetral do banco.

Cluster 6: Fraudes por Falha de Segurança de Conta (Risco Crítico) – Invasão real de contas digitais por hackers, cartões duplicados ou clonados virtualmente e transferências noturnas espúrias contornando os limites de segurança. Representa risco regulatório imediato de penalidades pela LGPD e exige auditoria de segurança cibernética.

Cluster 7: Conflitos de Tarifas e Débitos em Conta (Risco Médio) – Questionamentos e conflitos acerca de tarifas de manutenção de conta corrente aplicadas a clientes elegíveis ao Pacote de Serviços Essenciais gratuito determinado pelo Banco Central.

5. Projeções Gráficas e Mapeamento Geométrico

Para tornar a modelagem multidimensional humana e auditável, o espaço vetorial foi reduzido via t-SNE. Os gráficos confirmam que a inteligência artificial segmentou as dores do cliente em "ilhas semânticas" coesas.

5.1 Projeção Bidimensional (2D)




Figura 3: Projeção Bidimensional (2D)

Leitura Técnica: O plano cartesiano 2D revela fronteiras claras entre os grupos. Queixas com foco em fraudes ficam agregadas isoladamente, evidenciando que o modelo identificou o sentido real das palavras sem sofrer interferência de gírias e erros ortográficos.

5.2 Projeção Tridimensional (3D)

Mapeamento Semântico de Reclamações (Projeção t-SNE 3D)




Figura 4: Projeção Tridimensional (3D)

Leitura Técnica: A inclusão do eixo de profundidade topográfica (Z) mostra o distanciamento exato de clusters de altíssimo risco regulatório. O isolamento espacial fundamenta a necessidade da criação de ilhas operacionais apartadas do SAC padrão.

6. Plano de Ação Estratégico

- **Implementação de "Fast-Track" na Ouvidoria:** Configurar a esteira de triagem baseada nos metadados do agente JSON para intervenções urgentes (Clusters 5 e 6).
- **Mascaramento Automático de Dados (LGPD):** Implementação mandatória de camadas de Regex anonimizadoras em D-0 no trâmite interno da aplicação agente_analise.py.
- **Evolução de Algoritmos Preditivos:** Transição em Roadmap do K-Means para algoritmos baseados em densidade (HDBSCAN), visando mitigar anomalias e manifestações ilógicas.